

光学学报

基于指纹修正与网络融合算法的可见光定位系统应用

于建勇¹, 胡晓莉^{2*}, 王倩¹, 秦岭^{1*}, 王凤英³, 寇新超¹¹内蒙古科技大学数智产业学院(网络安全学院), 内蒙古 包头 014010;²内蒙古科技大学自动化与电气工程学院, 内蒙古 包头 014010;³内蒙古科技大学工程训练中心, 内蒙古 包头 014010

摘要 为了提高矿井下的可见光定位精度,结合点云技术模拟真实矿井环境,提出了一种Transformer融合MobileNetV3网络(ViT-MNV3)的可见光三维定位系统。该系统通过Transformer多头注意力模块,捕捉输入序列不同部分间的关系,以学习全局特征,从而表现出更优越的性能。该系统考虑了矿井墙面对光的反射、接收端高度以及倾斜等因素对定位结果的影响,面对接收端倾斜问题,通过引入可变增益因子来修正垂直接收指纹库并匹配倾斜接收功率。仿真结果表明,在 $4.0\text{ m}\times 3.0\text{ m}\times 2.5\text{ m}$ 的模拟空间内,该方法的均方根定位误差为 5.42 cm ,最大误差控制在 13.51 cm 以内。在实际环境中,三维定位均方根误差为 10.95 cm ,其中90%的误差在 25 cm 以内,基于修正功率的定位结果均方根误差为 21.43 cm 。实验结果表明,该系统能够有效满足矿井下的定位需求。

关键词 可见光定位; MobileNetV3; 多头注意力; 点云技术; 指纹库修正

中图分类号 TN929.12

文献标志码 A

DOI: 10.3788/AOS250821

1 引言

随着科技水平的提高,人们对定位精度的需求日益增加。与室内理想环境相比,复杂的矿井环境有诸多不确定性因素,这增大了矿井下定位的难度。目前常用的定位技术有Wi-Fi、蓝牙、超声波、红外、射频识别(RFID)和超宽带(UWB)等^[1-4],然而基于超声波、红外与超宽带的定位技术的成本高昂,基于Wi-Fi、蓝牙、射频识别的定位系统容易受到多径效应和电磁干扰的影响,从而导致定位精度降低。可见光通信(VLC)作为一种无线通信技术,其不受电磁干扰影响且不受无线频谱限制,具有较高的带宽和安全性能,有着巨大应用潜力。基于VLC,可见光定位(VLP)应运而生^[5-7]。在矿井下应用可见光系统时,由于其具有成本低廉、方便快捷、安全性高等优点,因此越来越受到研究人员的关注。

目前常用的基于测距的定位方法有接收信号强度(RSS)、到达时间(TOA)、到达时间差(TDOA)和到达角度(AOA)等^[8-10]。其中,基于接收信号强度的指纹定位方法具有设备简单、操作方便等优点,通过深度学习网络训练指纹数据库,能够得到较高的定位精度,近年来受到广泛研究。张慧颖等^[11]研究了可见光定位过程,

并基于接收信号强度比值建立数据库。此外,还改进了北方苍鹰算法(NGO),进而优化Elman神经网络。利用该网络对数据库进行训练,实现了良好的定位效果。胡晓莉等^[12]探究了障碍物对可见光定位系统的影响。在模拟环境中,基于点云技术导入真实的矿井墙壁与障碍物,从而建立真实的矿井环境。Bastiaens等^[13]详细说明了可见光定位的方法与过程,深入分析了该技术的固有特性和基本原理,并讨论了可见光定位系统的组成部分和定位方法。Deng等^[14]提出了一种基于Inception模块和高效的通道注意力(ECA)机制的卷积神经网络三维可见光定位系统,利用卷积神经网络对指纹数据进行特征提取,提高了定位精度。Apolo等^[15]展示了基于成像多输入多输出(MIMO)配置和人工神经网络的高精度二维/三维室内可见光定位系统,在典型的室内环境中取得了良好的定位效果。Wang等^[16]通过引入黑翅风筝算法来优化室内可见光三维定位系统,有效解决了传统方法在复杂环境下精度不足的问题。邓莉君等^[17]提出了一种基于到达角的光功率指纹数据自修正定位方法,通过引入可变增益因子对垂直接收链路损耗指数模型进行修正,得到与其维度和粒度相同的倾斜指纹库,通过倾斜指纹库与实际倾斜采集功率进行匹配,得到了良好的定位效果。

收稿日期: 2025-03-31; 修回日期: 2025-04-26; 录用日期: 2025-05-22; 网络首发日期: 2025-05-23

基金项目: 国家自然科学基金项目(62161041)、内蒙古自治区自然科学基金项目(2024LHMS06017)、内蒙古自治区高等学校科学研究项目(NJZY23077)、内蒙古自治区直属高校基本科研业务费项目(2023XKJX022)

通信作者: *hxl7756@163.com; *qinling1979@imust.edu.cn

综上所述,在可见光定位领域,当前研究主要集中于二维定位方法,然而矿井环境下工作人员位置存在动态变化,因此三维定位技术更适用于井下人员定位。此外,现有定位系统的信道模型过于理想化,难以适应复杂环境下的应用场景。因此本文引入点云技术,以还原定位系统中信道模型的真实性和,还考虑了接收端随机高度、随机倾斜等因素,最终建立了定位系统中真实的信道模型。为了解决接收端倾斜状态接收的光功率与垂直指纹数据库不匹配问题,引入可变增益因子来修正垂直数据库,使其与倾斜光功率相匹配。通过 Transformer 融合 MobileNetV3 网络 (ViTs-MNV3),凭借多头注意力强大的学习能力,充分学习指纹数据

库的全局特征,从而提高定位精度。

2 可见光定位系统

2.1 传统 VLC 信道理想模型

理想的矿井模型被模拟为双侧墙面光滑的长方体通道结构。在模型中,视距链路(LOS)在发射机辐射角范围与接收机检测角范围之内,无任何阻碍,还是空间对准的直射路径。链路中的直射增益是 VLC 系统接收功率的主要贡献,模型中的发射光源为发光二极管(LED),该光源符合朗伯辐射,在建立指纹数据库过程中,第 n 处 LOS 的信道增益表达式^[18]可表示为

$$H_{\text{LOS}} = \begin{cases} \frac{(m+1)A_p}{2\pi d_n^2} \cos^m(\phi_n) \cdot \cos \theta_n \cdot T(\theta_n) \cdot g(\theta_n), & 0 \leq \theta_n \leq \theta_{\text{FOV}} \\ 0, & \text{else} \end{cases} \quad (1)$$

式中: A_p 为接收端光电探测器(PD)的物理接收面积; θ_n 为传输光信号的角度,其值大于等于0且小于半视场角(FOV; θ_{FOV}); m 为朗伯模式数,其值与发射源的半功率角 $\Phi_{1/2}$ 有关; d_n 为发射源与PD之间的距离; ϕ_n 为发射源到接收端的直射光线的辐射角; $T(\theta_n)$ 为接收端滤光器; $g(\theta_n)$ 为聚光器增益。

经过墙面多次反射后,光功率的增益显著衰减,因此只考虑一次反射增益对接收光功率的影响。模型中的非视距链路(NLOS)是指在发射机辐射角内发射的光源经过墙面一次反射后,入射到接收机检测角内所走的路径。其中反射增益是 VLC 系统接收功率的次要贡献。模型中 NLOS 的信道增益表达式^[19]可表示为

$$H_{\text{NLOS}}^{(1)} = \begin{cases} \frac{(m+1)A_p}{2\pi} \sum_{i=1}^I \frac{\Delta A_i \rho}{d_{ui}^2 d_{in}^2} \cos^m(\phi_{ui}) \cdot \cos \theta_{ui} \cdot \cos \phi_{in} \cdot \cos \theta_{in} \cdot T(\theta_{in}) \cdot g(\theta_{in}), & 0 \leq \theta \leq \theta_{\text{FOV}} \\ 0, & \text{else} \end{cases} \quad (2)$$

式中: I 为理想墙面划分反射面元的总个数; ΔA_i 为反射面元的面积; ρ 为墙面反射系数; d_{ui} 为发射源到反射面元的距离; d_{in} 为反射面元到PD的距离; ϕ_{ui} 为发射源到反射面直射光线的辐射角; θ_{ui} 为反射面光线的入射角,此时墙面法向量垂直于墙面; ϕ_{in} 为反射面的辐射角; θ_{in} 为接收机PD的入射角。

结合信道视距链路与非视距链路,可以得到模型的总信道增益为

$$H = H_{\text{LOS}} + H_{\text{NLOS}}^{(1)} \quad (3)$$

接收机所接收到的总功率为总信道增益与LED发光功率(P_{LED})的乘积,具体表达式为

$$P = HP_{\text{LED}} \quad (4)$$

2.2 真实环境 VLC 信道模型

本研究基于理想的信道模型,建立了真实环境的 VLC 信道模型,如图1所示。与理想的模型相比,在矿井模型中,通过点云技术引入了凹凸不平的点云墙面。点云墙面会对光产生不规则的漫反射,这种不规则的反射会增加可见光信号传输的复杂性,进而影响可见




图1 真实环境信道模型

Fig. 1 Real environment channel model

光的定位精度,从而产生较大的定位误差。因此,为实现矿井定位系统的有效构建,需对上述影响因素进行深入分析。

利用ZED2深度相机扫描矿井内部凹凸不平的墙面,得到点云数据。经过点云优化^[20]后,将点云数据导

入模拟的仿真实空间中,建立基于点云模拟的矿井环境。使用Delaunay三角剖分算法^[21]将墙面点云划分为 w 个微元三角形,求得每一个微元三角形面积 ΔS_w 、中心坐标 (x_w, y_w, z_w) 和法向量 $\mathbf{n}'_w$,然后计算墙面反射链路的信道增益,具体表达式为

$$H'_{\text{NLOS}} = \begin{cases} \frac{(m+1)A_p}{2\pi} \sum_{w=1}^w \frac{\Delta S_w \rho}{d_{tw}^2 d_{wn}^2} \cos^m(\phi_{tw}) \cdot \cos \theta_{tw} \cdot \cos \phi_{wn} \cdot \cos \theta_{wn} \cdot T(\theta_{wn}) g(\theta_{wn}), & 0 \leq \theta \leq \theta_{\text{FOV}} \\ 0, & \text{else} \end{cases} \quad (5)$$

式中: d_{tw} 为发射源到微元的距离; d_{wn} 为微元到PD的距离; ϕ_{tw} 为发射源到反射面直射光线的辐射角; θ_{tw} 为反射面光线的入射角,此时墙面法向量垂直于墙面; ϕ_{wn} 为反射面的辐射角; θ_{wn} 为接收机PD的入射角。在真实环境模型中,直射链路不受墙面的影响,计算方法可参考理想环境LOS的信道增益表达式,即式(1)。

3 接收端模型与指纹数据库

3.1 接收端模型

将工人安全帽表示为半球体,以帽底中心为原点 o 建立空间坐标系。4个接收端($P_i, i=1, 2, 3, 4$)固定

在安全帽上,结构如图2所示。帽顶中心点为 o' ,设其坐标为 (x_i, y_i, z_i) ,法向量为 $\mathbf{n}_o = (0, 0, 1)$, oo' 的距离为 H 。其中: β_i 为 P_i 的方位角,分别为 0° 、 90° 、 180° 和 270° ; a 为 P_i 到 z 轴的水平距离; b 为 P_i 到 xoy 平面的垂直距离; c 为原点到 P_i 的距离; φ 为 P_i 与 z 轴的倾斜角; h 为 P_i 到帽顶所在平面的垂直距离。

已知 P_i 的方位角 β_i 与倾斜角 φ ,则 P_i 的法向量可表示为

$$\mathbf{n}_i = \begin{bmatrix} \sin \varphi \cdot \cos \beta_i \\ \sin \varphi \cdot \sin \beta_i \\ \cos \varphi \end{bmatrix} \quad (6)$$




图2 安全帽PD分布图。(a)俯视图;(b)三维立体图;(c)旋转倾斜图

Fig. 2 PD distribution of safety helmet. (a) Top view; (b) 3D stereogram; (c) rotation tilt diagram

设 P_i 的坐标为 (x_i, y_i, z_i) ,则 P_i 与帽顶 o' 之间的坐标关系为

$$\begin{cases} x_i = x_t + a \cos \beta_i \\ y_i = y_t + a \sin \beta_i \\ z_i = z_t - h \end{cases} \quad (7)$$

在矿井作业环境下,工人头部持续处于运动状态,接收端的法向量随工人头部运动发生的变化如图2(c)所示。虚线圆 P_i 为正常位置,实线圆 P'_i 为旋转后的位置,实心圆 P''_i 为经过旋转与倾斜后的位置。正常情况下,接收端4个PD的入射角为法向量与入射光线的夹角。当工人的头部随机旋转角度 ω ($0^\circ \leq \omega \leq 360^\circ$)且倾斜角度 γ ($0^\circ \leq \gamma \leq 90^\circ$)时,接收端视距链路的入射角由 θ_n 变为 θ'_n ,非视距链路的入射角由 θ_{wn} 变为 θ'_{wn} ,具体表达式为

$$\theta'_n = \arccos \left(\frac{\mathbf{V}_n \cdot \mathbf{n}'_i}{\|\mathbf{V}_n\| \cdot \|\mathbf{n}'_i\|} \right), \theta'_{wn} = \arccos \left(\frac{\mathbf{V}_{wn} \cdot \mathbf{n}'_i}{\|\mathbf{V}_{wn}\| \cdot \|\mathbf{n}'_i\|} \right) \quad (8)$$

式中: $\mathbf{V}_n$ 为LED指向接收端第 n 个PD位置的向量, $\mathbf{V}_n = (x_d - x_i, y_d - y_i, z_d - z_i)$; $\mathbf{V}_{wn}$ 为第 w 个反射面元指向第 n 个PD位置的向量, $\mathbf{V}_{wn} = (x_w - x_i, y_w - y_i, z_w - z_i)$; $\mathbf{n}'_i$ 为接收端的法向量。将 θ'_n 与 θ'_{wn} 分别代入式(1)与式(5),即可计算接收端倾斜时视距链路与非视距链路的信道增益。

3.2 指纹数据库的建立及评估标准

在建立指纹数据库的过程中,通过记录垂直接收器在每个点的光功率值、旋转角、倾斜角及对应的坐标来完成指纹数据库的构建。以第 q 个接收平面上第 j

个点为例,其接收功率可表示为

$$P_{qj} = (P_{j1}, P_{j2}, P_{j3}, P_{j4}, \omega_j, \gamma_j, x_j, y_j, z_j) \quad (9)$$

式中: P_{j1} 为第 j 个位置的第 1 个 PD 的接收光功率; ω_j 为该位置安全帽的旋转角度; γ_j 为该位置安全帽的倾斜角度。采用均方根误差(RMSE)作为定位误差评估标准来进行误差分析,其计算方式为

$$E_{\text{RMSE}} = \sqrt{\frac{\sum_{i=1}^N [(x_{ai'} - x_{pi'})^2 + (y_{ai'} - y_{pi'})^2 + (z_{ai'} - z_{pi'})^2]}{N}} \quad (10)$$

式中: N 为目标点个数; $(x_{ai'}, y_{ai'}, z_{ai'})$ 为真实坐标; $(x_{pi'}, y_{pi'}, z_{pi'})$ 为预测坐标。

3.3 垂直指纹数据库修正

通常情况下,通过垂直接收器接收光功率并建立指纹数据库。但在实际应用中,安全帽接收端倾斜会导致接收功率产生误差。本研究利用角度相关的可变增益因子来修正垂直指纹库,以生成倾斜指纹库,使其与真实倾斜接收情况相匹配,从而降低定位误差。

在接收端旋转倾斜接收光功率时,图 1 中的接收端入射角 $\theta_n^{[22]}$ 表示为

$$\theta_n = \arccos \left[\frac{(x_1 - x_b) \cos \omega \cdot \sin \gamma + (y_1 - y_b) \sin \omega \cdot \sin \gamma + (z_1 - z_b) \cos \gamma}{d_0} \right] \quad (11)$$

式中: (x_1, y_1, z_1) 为 LED 位置坐标; (x_b, y_b, z_b) 为接收端位置坐标; d_0 为 LED 与接收端之间的距离。

垂直接收器的整体法向量垂直向上,满足发射端辐射角 ϕ 与接收端入射角 θ 的余弦值相等,即 $\cos \phi = \cos \theta = l_h/d$, l_h 为 LED 到接收端所在平面的垂直距离, d 为 LED 到 PD 的直线距离。当安全帽接收端发生倾斜时,模型的辐射角未发生变化, $\cos \phi = l_h/d$ 依然成

立,因此该入射角的余弦值可以看作是在垂直接收的基础上,由角度和位置变化而引入的一个可变增益因子。可变增益因子随接收端坐标、旋转角度、倾斜角度的变化而变化,可将其定义为 $T(x_b, y_b, z_b, \omega, \gamma)$ 。当接收端发生旋转倾斜后,其入射角的余弦值可表示为 $\cos \theta = (l_h/d) \cdot T(x_b, y_b, z_b, \omega, \gamma)$,因此可以得到可变增益因子的表达式为

$$T(x_b, y_b, z_b, \omega, \gamma) = [(x_1 - x_b) \cos \omega \cdot \sin \gamma + (y_1 - y_b) \sin \omega \cdot \sin \gamma + (z_1 - z_b) \cos \gamma] / l_h \quad (12)$$

已知某位置的垂直接收光功率(P_{ver})时,则此位置的旋转倾斜光功率表示为

$$P_{\text{til}} = P_{\text{ver}} \cdot T(x, y, z, \omega, \gamma) \quad (13)$$

在实际应用中,针对接收端旋转和倾斜的情况,本研究采用可变增益因子对垂直接收指纹数据库进行转换,构建适用于任意姿态角的倾斜指纹数据库。将构建的倾斜指纹库与实测倾斜状态下的接收光功率数据进行匹配,可显著降低定位系统的倾斜误差。

4 ViTs-MNV3 模型

4.1 网络融合

本研究选取标准的轻量级 CNN 网络 MobileNetV3^[23] 为基础网络,引入轻量级 Transformer 架构并与之结合组成 ViTs-MNV3。为了使两种网络能够更好地融合,分离了其中的令牌混合器和通道混合器。如图 3(a) 所示,在原始 MobileNetV3 中,通道混合器由 1×1 扩展卷积和投影层组成,而令牌混合器使用 3×3 深度卷积处理空间信息,二者之间相互耦合。为了使其分离,将 3×3 深度卷积层向上移动。压缩与激励层(SE)^[24] 依赖于空间信息的交互,需要放在深度卷积层之后。在分离过程中,通过结构重参数化技术^[25] 减少与跳跃连接相关的计算和内存成本,分离后的模型如图 3(b) 所示。在推理过程中,深度卷积多分

支结构可融合为单分支结构,以节省计算成本,最终的融合结果如图 3(c) 所示,将图 3(c) 所示的模块定义为深度融合块(deep fusion block)。

4.2 ViTs-MNV3 框图

基于融合网络(ViT-MNV3)的矿井下定位网络总体框图如图 4 所示,该网络由起始模块(stem)、深度融合块(deep fusion block)、下采样层(downsample)、池化层(pooling)、全连接层(fully connected layer)、压缩与激励层(SE layer)和前馈神经网络(FFN)构成。该网络以一维光功率数据作为输入,输入数据先经过起始模块^[26]。起始模块采用连续堆叠的 3×3 卷积结构,既能够保证计算效率,又能够提高特征提取精度。在起始模块后,数据经过 4 个阶段,每个阶段为深度卷积引入多分支拓扑结构,以提高特征提取性能。训练时,将深度卷积多分支结构合并为单分支结构,以消除多分支带来的额外计算和内存成本,合并过程如图 3(b)、(c) 所示。在单分支结构后面连接 SE 模块,SE 模块通过显式建模通道关系,使网络能够自适应地强调重要特征并抑制不重要的特征,从而提升表示能力。随后通过 FFN 提取和映射输入特征到输出空间。在每个阶段的输出后连接下采样层,通过深度融合块的前置融合和 FFN 的后置连接,增强了网络的表征能力。下采样过程通过深度 3×3 卷积和 1×1 卷积来调制通道




图3 区块设计。(a)原始的MobileNetV3块;(b)令牌混合器与通道混合器分离后的模型;(c)深度融合块
Fig. 3 Block design. (a) Original MobileNetV3 block; (b) separate token mixer and channel mixer; (c) deep fusion block

维度,以增强整体架构。在最后输出阶段后面连接分类器,将网络学习到的复杂特征映射到目标任务的输出空间。分类器主要由池化层和全连接层两部分组成,数据通过池化层保留关键特征信息,防止过拟合,并提升模型泛化能力和鲁棒性。全连接层是网络输出的核心,其核心功能是进行特征整合与分类,实现特征

空间到目标空间的转换及决策输出。

网络模型在起始模块后经过4个处理阶段,每个阶段的步骤、批次大小和通道尺寸相同,处理数据的密度随阶段依次增加。为了确保模型推算效率,在所有模块上使用 3×3 卷积,并通过SE层来弥补卷积在缺乏数据驱动属性方面的局限性。最终结合了轻量级




图4 ViTs-MNV3算法的框图
Fig. 4 Block diagram of ViTs-MNV3 algorithm

Transformer 的自注意力优势与 MobileNetV3 的高效结构。

4.3 网络超参数

在深度网络训练数据过程中,超参数值对训练结果有着重要影响。进一步分析网络训练过程中不同批次大小对定位结果的影响,如表 1 所示。综合考虑不同的批次大小对模型的影响,选择批次大小为 128,在此批次下的真实环境均方根定位误差达到了 10.95 cm,平均误差为 8.36 cm,满足矿井下对矿工人员的定位要求。

表 1 不同批次大小的均方根误差与平均误差

Table 1 Root mean square error and mean error for different batch sizes

Batch size	RMSE /cm	Mean error /cm	Training time /min
32	12.62	11.93	11.1
64	11.66	9.01	6.8
128	10.95	8.36	4.2
256	11.42	10.15	3.7
512	12.03	12.56	2.5

在深度网络的训练过程中,通过不断迭代网络,逐步将训练模型向最佳状态靠拢。随着迭代次数的增加,定位精度呈先增加后饱和的变化趋势,当迭代次数超过临界阈值后,系统将面临过拟合风险。为了寻求最佳迭代参数,本研究采用均值比较方法,比较了不同迭代次数下的均方根误差值,不同迭代次数下的损失函数曲线如图 5 所示。当迭代次数到达 1000 时,损失趋于饱和,因此将迭代次数设置为 1000。




图 5 损失函数随迭代次数的曲线

Fig. 5 Curve of loss function with number of iterations

4.4 网络算法对比

为了全面评估不同网络架构在定位任务中的表现并突出所提网络的优势,在训练参数设置一致的条件下,包括批次大小、迭代次数和学习率等,采用真实环境采集的三维空间数据作为数据集,对比所提网络与

MobileNetV3 网络、Transformer 神经网络、反向传播 (BP) 神经网络、长短时记忆 (LSTM) 网络的定位误差与复杂度。其中,所提网络是 MobileNetV3 网络与 Transformer 神经网络的深度融合体,因此与 MobileNetV3 网络、Transformer 神经网络对比更能体现出所提算法的优势。BP 神经网络与 LSTM 网络是深度学习中常见并具有代表性的深度学习网络,与之对比更能体现出所提算法的创新性。所有网络的输入为经过标准化的序列输入。所提网络与 Transformer 神经网络的输出为编码器生成序列,激活函数分别为 Sigmoid (SE 模块) 和 Softmax (注意力权重); MobileNetV3 网络的输出为多尺度特征序列,激活函数为 Sigmoid; BP 神经网络的输出方式为线性输出,激活函数为 Softmax; LSTM 网络的输出为时间序列,激活函数为 Softmax。

网络定位误差与复杂度对比结果如表 2 所示。定位误差即通过对比各个预测点与原始点之间的均方根距离和平均距离来衡量网络的定位效果。利用浮点运算次数 (FLOPs) 来衡量网络复杂情况,网络越复杂,其训练时间越久。从表 2 可以看出,单一的 MobileNetV3 网络与单一的 Transformer 神经网络的均方根定位误差较大,其中 MobileNetV3 的网络复杂度最高,运行时间最长。而所提 ViTs-MNV3 的定位误差与复杂度明显降低。相较于 BP 神经网络,所提网络的网络复杂度低且运行时间少,均方根定位误差降低了 32.2%;相较于 LSTM 网络,所提网络的网络复杂度与运行时间与之相近,但均方根定位误差降低了 26%。

表 2 不同网络算法的定位误差与复杂度对比

Table 2 Comparison of positioning errors and complexity of different network algorithms

Positioning algorithm	RMSE /cm	Mean error /cm	FLOPs / 10^9	Time /min
MobileNetV3	28.30	23.68	2.69	10.3
Transformer	25.80	22.95	1.58	4.6
ViTs-MNV3	10.95	8.36	1.42	4.2
BP	16.15	15.77	1.67	5.9
LSTM	14.80	14.61	1.46	4.5

MobileNetV3 网络难以建模全局空间关系,导致远距离目标关联失效; Transformer 神经网络的分辨率较低,会导致细节丢失; BP 神经网络的全连接结构的数据计算量大且缺乏平移不变性; LSTM 时序结构对静态数据定位任务冗余,且难以并行化。所提网络结合 Transformer 与 MobileNetV3 网络的优势,提高了全局建模能力并注重局部特征提取,定位误差明显降低。为了更加突出所提网络算法的定位效果,对比了 5 种不同网络算法的定位误差累积分布,如图 6 所示。




图6 定位误差累积分布图

Fig. 6 Cumulative distribution of positioning errors

在矿井环境中,墙面反射、微粒散射、外界光干扰等因素是定位误差的主要来源,不同网络的内部结构不同,对数据集的训练和处理方式也不同,因此网络训练后定位误差的占比也不同。从图6可以看出:针对所提网络,其误差在 25 cm 以内的占比为 90%;针对 BP 神经网络,其误差在 12.12 cm 以内的占比为 73%,在 25 cm 的占比为 83%;针对 MobileNetV3 网络,其误差在 25 cm 以内的占比为 72%;针对 Transformer 网络,其误差在 25 cm 以内的占比为 78%;针对 LSTM 网络,其误差在 25 cm 以内的占比为 86%。相比之下,所提网络的误差超过 25 cm 的占比少,整体上优于其他 4 种网络。

5 仿真及结果分析

5.1 仿真环境及参数设置

本研究将仿真模拟空间大小设置为 $4.0\text{ m} \times 3.0\text{ m} \times 2.5\text{ m}$ 。在模型中,点云墙面数据的有效范围为 $4.0\text{ m} \times 2.5\text{ m}$,超出范围部分忽略不计。LED 光源放于模型顶部中间位置,坐标为 $(2.0\text{ m}, 1.5\text{ m}, 2.5\text{ m})$ 。以 15 cm 的间隔设置采样点来采集训练集光功率,建立指纹数据库,以 20 cm 的间隔设置采样点来采集测试集光功率。接收端放置于网格中心位置,模型的具体参数如表3所示。

本实验神经网络定位模型运行环境是基于 PyTorch 的深度学习开源框架库构建,ViTs-MNV3 模型的参数如表4所示。

5.2 理想环境 ViTs-MNV3 网络定位结果

在理想状态下,不考虑任何干扰因素,则理想环境的墙面反射可视为镜面反射,墙面被划分为若干个反射面元,通过每个面元的反射光功率来计算某一位置的反射功率。本研究分别选取 7 个不同高度的接收平面,整合 7 个高度的训练集功率数据为一体,通过 ViTs-MNV3 网络训练后进行三维空间定位,定位结果如图7所示。

表3 信道参数设置

Table 3 Channel simulation parameter

Symbol	Parameter	Value
$L \times W \times H$	Room size / ($\text{m} \times \text{m} \times \text{m}$)	$4.0 \times 3.0 \times 2.5$
φ	Tilt angle of PD / ($^\circ$)	30
ω	Rotation angle of safety helmet / ($^\circ$)	45
γ	Tilt angle of safety helmet / ($^\circ$)	15
A_p	Physical area of photo-detector / cm^2	1
m	Lambert index	1
ρ	Reflection coefficient	0.5
$T(*)$	Gain of optical filter	1
$g(*)$	Gain of optical concentrator	2.55
FOV	Field of view / ($^\circ$)	90
$\Phi_{1/2}$	Semi-angle at half power / ($^\circ$)	70
P_t	Average transmitted power / W	20

表4 模型训练参数

Table 4 Model training parameters

Symbol	Parameter	Value
epochs	Model iterations	1000
k_s	Kernel size	3
e_f	Expansion factor	2
o_c	Output channel	128
h_s	Hard-swish	1
stride	Stride length	2
b_s	Batch size	128




图7 理想环境三维定位结果图

Fig. 7 Ideal environment 3D positioning result map

从图7可以看出,所提训练网络在三维空间中表现出优异的定位性能,三维空间整体定位均方根误差仅为 2.36 cm,平均误差为 3.2 cm,定位误差精度为 cm 量级。为了验证所提网络在随机高度下的定位结果,

选取工人在矿井中常见的坐、蹲、半蹲、直立 4 个姿态高度进行了仿真验证, 4 个姿态高度分别为 0.92、1.18、1.36、1.82 m, 4 个随机高度下的均方根定位误差为 2.64 cm。当接收端的高度随机时, 仿真定位仍然拥有高精度的定位结果。

5.3 考虑墙面反射的定位结果

本研究采用深度相机对真实矿井通道的双侧墙面

进行三维扫描, 获取高精度点云数据。墙面点云经过优化后导入信道模型中的相应位置, 通过 Delaunay 三角剖分算法将点云墙面剖分为无数个小三角形, 墙面局部点云剖分结果如图 8 所示。其中, 图 8(a) 为墙面局部点云。为了更好地展示墙面表面特征, 将此点云经旋转, 可以得到图 8(b), 经过 Delaunay 三角剖分后墙面如图 8(c) 所示。




图 8 点云三角网格剖分。(a)墙面点云;(b)旋转后的墙面点云;(c)经 Delaunay 三角剖分后的墙面点云

Fig. 8 Point cloud triangulation. (a) Wall point cloud; (b) rotated wall point cloud; (c) wall point cloud after Delaunay triangulation

在墙面反射的模拟实验中, 设置接收端的高度为 1.2 m。墙面点云经过三角剖分后, 通过仿真得到信道模型光功率分布与真实墙面光功率定位误差, 如图 9

所示。图 9(a) 为左墙一次反射功率, 图 9(b) 为右墙一次反射功率, 图 9(c) 为总功率。对模型接收总功率进行可见光定位, 图 9(d) 为接收平面的定位结果。




图 9 光功率分布与定位误差。(a)左墙一次反射功率;(b)右墙一次反射功率;(c)总功率;(d)定位结果

Fig. 9 Optical power distributions and positioning errors. (a) Left wall primary reflected power; (b) right wall primary reflected power; (c) total power; (d) positioning results

由图 9 可知, 靠近墙面的位置受墙面反射影响较大, 真实点云墙面的表面凹凸不平, 其划分的微元平

面面积存在差异, 法向量方向呈现随机分布特性, 因此接收端功率分布图像呈现非均匀性。直射功率在

总功率中占主导作用,但受墙面反射的影响,真实墙面模型的定位误差与理想墙面相比明显增大。其中均方根误差为 5.42 cm,平均误差为 7.26 cm,最大误差为 13.51 cm。

5.4 接收端倾斜定位结果

通常情况下,采用垂直接收器建立指纹数据库,这种垂直采集的指纹数据库被用作训练集,通过深度

网络训练得到垂直指纹模型。工人在矿井下工作时,头部姿态不可避免地存在动态变化,安全帽发生倾斜是普遍现象。为了模拟工人头部倾斜的状态,模拟实验中将接收端旋转 45°并倾斜 30°,在这种状态下,将接收到的光功率值作为测试集。将测试集与垂直指纹训练模型进行定位匹配,所得仿真结果如图 10 所示。




图 10 接收功率与定位结果。(a)垂直仿真光功率分布;(b)倾斜仿真光功率分布;(c)倾斜光功率匹配垂直数据库的定位结果
Fig. 10 Received power and positioning results. (a) Vertical simulation of optical power distribution; (b) tilt simulation optical power distribution; (c) tilted optical power matching vertical database positioning results

图 10(a)为模拟垂直采集的训练集指纹数据库功率分布图,光功率分布比较均匀。图 10(b)为模拟发生旋转倾斜后的测试集光功率数据分布图,当光线与接收端法向量的夹角大于接收端入射角时,接收直射功率为 0。图 10(c)为倾斜光功率匹配垂直数据库的定位结果,均方根误差为 2.48 m,平均误差为 2.17 m。对比图 10(a)、(b)可知,发生倾斜之后的功率分布与垂直数据库完全不匹配,因此造成了极大的定位误差。

6 实际环境实验结果

6.1 实验环境

为了验证所提网络算法在实际应用中的定位效果,并探究接收端倾斜对定位效果的影响,采用功率修正的方法来修正垂直指纹数据库,以适应倾斜功率。在矿井真实环境中进行了验证试验,矿井实验场景如图 11 所示。

场景中调整 LED 的高度为 2.5 m 并放置于通道中心位置,以 LED 为中心选取地面 4.0 m×3.0 m 区域为光功率采集区域。在与接收端高度一致的情况下,以 15 cm 为间隔采集训练集指纹数据,共采集 567 个指纹数据;以 20 cm 为间隔采集测试集指纹数据,共采集 336 个指纹数据。LED 的发光功率为 20 W,接收端采用 4 个 PIN 光电二极管来接收光功率,并依据图 2 的排列顺序分别放置于安全帽的顶端。

6.2 真实环境三维定位结果

在真实环境中,选取 0.6、1.0、1.3、1.6 m 四个高度



图 11 矿井实验场景
Fig. 11 Experimental environment of the mine

进行光功率采集并制作垂直接收指纹数据库,其中包含 2268 个训练集指纹数据,1344 个测试集指纹数据。通过 ViTs-MNV3 训练数据库得到定位模型后,再与测试集匹配。通过系统地优化深度神经网络的超参数配置,包括网络迭代次数与批处理大小等关键训练参数,最终实现了定位误差的最小化。三维定位结果如图 12 所示,其三维定位均方根误差为 10.95 cm,平均误差为 8.36 cm。与仿真结果相比,真实环境中存在墙面反射,还存在微粒散射、其他光源干扰、接收端功率不稳定等多种不确定性因素,无法达到仿真的理想条件,实验结果不及仿真结果。但是实验结果仍然达到 cm 量级,且 90% 的误差小于




图 12 真实环境下不同高度三维定位结果

Fig. 12 3D positioning results at different heights in real environment

25 cm, 较大误差的占比少, 能够满足矿井下的人员定位需求。

6.3 功率修正定位结果

针对矿井中安全帽倾斜导致光功率数据失配、定位精度下降的问题, 采用基于可变增益因子的数据修正方法, 通过将垂直指纹库数据模拟倾斜处理, 使其匹配实际倾斜采集的功率值, 显著降低了倾斜带来的定位误差。

选取 1 m 高度采集的垂直功率作为训练集, 其功率分布如图 13(a) 所示。在相同高度下将接收端逆时针旋转 90° , 并向 PD 1 方向倾斜 30° 作为测试集的采集角度。基于该倾斜角度, 通过对垂直采集训练集的功率数据进行可变增益因子修正, 得到倾斜化功率数据如图 13(b) 所示。

为验证倾斜功率修正效果, 实验采集了 110 个点的实测倾斜数据, 与转换后的功率对比如图 14(a) 所示, 结果显示两者高度吻合, 证实了该方法的可行性。修正后的训练集与真实倾斜采集测试集匹配的定位结果如图 14(b) 所示, 均方根误差为 21.43 cm, 平均误差为 17.71 cm。与模拟环境中功率未修正前的定位结果进行对比, 定位误差有大幅度的减小。




图 13 真实环境功率分布。(a)垂直采集训练集功率分布;(b)垂直功率转换后的训练集倾斜功率分布

Fig. 13 Real environment power distribution. (a) Vertical acquisition training set power distribution; (b) skewed power distribution of the training set after vertical power transformation




图 14 功率修正效果与定位结果。(a)转换功率与真实采集功率对比图;(b)转换功率匹配真实采集功率定位结果图

Fig. 14 Power correction effect and positioning results. (a) Comparison between the converted power and the real collected power; (b) converted power matching real acquisition power positioning result plot

7 结 论

针对矿井下复杂环境,结合三维点云技术建立了真实环境可见光三维定位系统。此系统中包含墙面反射、接收端高度以及接收端倾斜等不同情况,会对定位结果产生不同程度的影响。其中接收端倾斜对定位结果影响最大,在 $4.0\text{ m} \times 3.0\text{ m} \times 2.5\text{ m}$ 的模拟空间中,其平均误差达到了 2.17 m ,严重影响了矿井下人员的定位。针对此情况,引入可变增益因子来修正垂直接收指纹数据库,使指纹数据库倾斜化以匹配倾斜接收光功率,最终提升定位精度。通过此方法还可以进一步扩展不同倾斜角度的数据库,节省了人工手动建立倾斜数据库的时间和精力。该系统定位算法通过融合 Transformer 神经网络与 MobileNetV3 网络,组成了 ViTs-MNV3,该网络在定位过程中具有优异的性能。此定位算法在仿真理想环境中的均方根定位误差达到 2.36 cm ,在有墙面反射的仿真环境中的均方根定位误差为 5.42 cm 。在真实环境中进行了验证实验,在真实环境中,垂直接收均方根定位误差为 10.95 cm ,经功率修正后的倾斜接收均方差定位误差为 21.43 cm ,相比于功率修正之前定位误差明显减小。

参 考 文 献

- [1] 朱瑞, 张丽杰. 多指纹融合和区域细化的 WiFi 室内定位方法[J]. 导航定位学报, 2024, 12(5): 62-69.
Zhu R, Zhang L J. Multi-fingerprint fusion and area refinement for WiFi indoor positioning methods[J]. Journal of Navigation and Positioning, 2024, 12(5): 62-69.
- [2] Wu C X, Wong I C, Wang Y P, et al. Experimental study of bluetooth indoor positioning using RSS and deep learning algorithms[J]. Mathematics, 2024, 12(9): 1386.
- [3] 卢鑫冉. 基于超声波的高精度室内定位系统设计[D]. 西安: 西安电子科技大学, 2023.
Lu X R. Design of high-precision indoor positioning system based on ultrasound[D]. Xi'an: Xidian University, 2023.
- [4] Wei Z, Chen J L, Tang H, et al. RSSI-based location fingerprint method for RFID indoor positioning: a review[J]. Nondestructive Testing and Evaluation, 2024, 39(1): 3-31.
- [5] 汝贵, 秦岭, 王凤英, 等. 基于光电二极管阵列传感器的可见光定位系统[J]. 光学学报, 2024, 44(21): 2106005.
Ru G, Qin L, Wang F Y, et al. Visible light positioning system based on photodiode array sensor[J]. Acta Optica Sinica, 2024, 44(21): 2106005.
- [6] Alhomayani F, Mahoor M H. Deep learning methods for fingerprint-based indoor positioning: a review[J]. Journal of Location Based Services, 2020, 14(3): 129-200.
- [7] Tran H Q, Ha C. Machine learning in indoor visible light positioning systems: a review[J]. Neurocomputing, 2022, 491: 117-131.
- [8] 雷思捷, 胡晓莉, 秦岭, 等. 井下可见光信道建模与应用的研究[J]. 中国激光, 2023, 50(11): 1106005.
Lei S J, Hu X L, Qin L, et al. Research on modeling and application of downhole visible light channel[J]. Chinese Journal of Lasers, 2023, 50(11): 1106005.
- [9] 郭立新, 王云鹏. 基于 TOA 与 AOA 算法的室内定位方法[J]. 东北大学学报(自然科学版), 2024, 45(8): 1115-1122.
Guo L X, Wang Y P. Indoor positioning method based on TOA and AOA algorithms[J]. Journal of Northeastern University (Natural Science), 2024, 45(8): 1115-1122.
- [10] Du P F, Zhang S, Chen C, et al. Demonstration of a low-complexity indoor visible light positioning system using an enhanced TDOA scheme[J]. IEEE Photonics Journal, 2018, 10(4): 7905110.
- [11] 张慧颖, 盛美春, 梁士达, 等. 基于 RSSR 融合 RNGO-Elman 神经网络的室内可见光定位[J]. 半导体光电, 2024, 45(3): 449-457.
Zhang H Y, Sheng M C, Liang S D, et al. Indoor visible-light localization based on received signal strength ratio using fused RNGO-elman neural network[J]. Semiconductor Optoelectronics, 2024, 45(3): 449-457.
- [12] 胡晓莉, 王倩, 秦岭, 等. 点云阴影信道模型及其在室内可见光指纹定位中的应用[J]. 中国激光, 2025, 52(2): 0206003.
Hu X L, Wang Q, Qin L, et al. Point cloud shadow channel model and its application in indoor visible-light fingerprint positioning[J]. Chinese Journal of Lasers, 2025, 52(2): 0206003.
- [13] Bastiaens S, Alijani M, Joseph W, et al. Visible light positioning as a next-generation indoor positioning technology: a tutorial[J]. IEEE Communications Surveys & Tutorials, 2024, 26(4): 2867-2913.
- [14] Deng B, Wang F Y, Qin L, et al. A visible light 3D positioning system for underground mines based on convolutional neural network combining inception module and attention mechanism[J]. Photonics, 2023, 10(8): 918.
- [15] Apolo J A, Osahon I N O, Ortega B, et al. Experimental demonstrations of high-accuracy 3D/2D indoor visible light positioning using imaging multiple-input multiple-output receivers and artificial neural networks[J]. IET Optoelectronics, 2025, 19(1): e70000.
- [16] Wang J H, Wang X Q, Jia C C, et al. Indoor visible light 3D localization system based on black wing kite algorithm[J]. IEEE Access, 2025, 13: 20960-20973.
- [17] 邓莉君, 樊养余, 赵琼. 基于到达角的室内可见光指纹自修正定位方法[J]. 光学学报, 2025, 45(8): 0806001.
Deng L J, Fan Y Y, Zhao Q. Indoor visible light fingerprint self-modified positioning method based on angle of arrival[J]. Acta Optica Sinica, 2025, 45(8): 0806001.
- [18] Yahia S, Meraihi Y, Ramdane-Cherif A, et al. A survey of channel modeling techniques for visible light communications[J]. Journal of Network and Computer Applications, 2021, 194: 103206.
- [19] Játiva P P, Azurdia-Meza C A, Sánchez I, et al. A VLC channel model for underground mining environments with scattering and shadowing[J]. IEEE Access, 2020, 8: 185445-185464.
- [20] Yu J Y, Hu X L, Wang Q, et al. Visible light channel modeling and application in underground mines based on transformer point clouds optimization[J]. Optics Communications, 2025, 578: 131485.
- [21] 李佳男, 王泽, 许廷发. 基于点云数据的三维目标检测技术研究进展[J]. 光学学报, 2023, 43(15): 1515001.
Li J N, Wang Z, Xu T F. Three-dimensional object detection technology based on point cloud data[J]. Acta Optica Sinica, 2023, 43(15): 1515001.
- [22] Yang S H, Kim H S, Son Y H, et al. Three-dimensional visible light indoor localization using AOA and RSS with multiple optical receivers[J]. Journal of Lightwave Technology, 2014, 32(14): 2480-2485.
- [23] Howard A, Sandler M, Chen B, et al. Searching for MobileNetV3[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV), October 27–November 2, 2019, Seoul, Republic of Korea. New York: IEEE Press, 2019: 1314-1324.
- [24] Hu J, Shen L, Albanie S, et al. Squeeze-and-excitation networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(8): 2011-2023.

- [25] Ding X H, Zhang X Y, Ma N N, et al. [RepVGG: making VGG-style ConvNets great again](#)[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), June 20–25, 2021, Nashville, TN, USA. New York: IEEE Press, 2021: 13728-13737.
- [26] Xiao T T, Singh M, Mintun E, et al. [Early convolutions help transformers see better](#)[EB/OL]. (2021-06-28) [2024-12-12]. <https://arxiv.org/abs/2106.14881v3>.

Application of Visible Light Positioning System Based on Fingerprint Correction and Network Fusion Algorithms

Yu Jianyong¹, Hu Xiaoli^{2*}, Wang Qian¹, Qin Ling^{1**}, Wang Fengying³, Kou Xinchao¹

¹*School of Digital and Intelligent Industry, Inner Mongolia University of Science and Technology, Baotou 014010, Inner Mongolia, China;*

²*School of Automation and Electrical Engineering, Inner Mongolia University of Science and Technology, Baotou 014010, Inner Mongolia, China;*

³*Engineering Training Center, Inner Mongolia University of Science and Technology, Baotou 014010, Inner Mongolia, China*

Abstract

Objective Visible light positioning (VLP) has demonstrated promising outcomes in indoor environments. However, underground mines present significant challenges compared to ideal indoor conditions, substantially increasing positioning complexity. Traditional indoor positioning methodologies no longer adequately address underground mine positioning requirements. Consequently, developing a reliable and efficient positioning system for underground mines has become a critical challenge. In underground mining operations, the unpredictable nature of workers' head movements and variations in receiver height significantly impact visible light positioning performance. Thus, three-dimensional (3D) positioning presents a more suitable approach for personnel tracking in underground environments. During operations, head tilting introduces directional reception uncertainties, causing random fluctuations in received signal strength (RSS). This substantially reduces the accuracy of fingerprinting methods based on vertical received power and potentially leads to positioning failures. Moreover, reflections from irregular mine walls affect the optical power received by the photodetector (PD), resulting in unstable received power signals near walls and increased positioning errors. To improve positioning accuracy in complex underground environments, this study implements an inclination correction for vertical received optical power to accommodate tilted reception conditions (fingerprint correction). Additionally, we introduce a deep learning network that combines Transformer with MobileNetV3 (ViTs-MNV3) to process datasets from complex underground mine environments. Using point cloud technology, we simulate authentic mine environments to conduct comprehensive research on visible light positioning under these challenging conditions.

Methods Currently, commonly used ranging-based positioning methods include RSS, time of arrival (TOA), time difference of arrival (TDOA), and angle of arrival (AOA). Among these approaches, fingerprinting-based positioning methods utilizing RSS are extensively researched due to their simple hardware requirements, operational simplicity, and capacity to achieve high positioning accuracy when integrated with deep learning networks for fingerprint database training. This study initially employs a conventional method to vertically collect optical power data for establishing a fingerprint database. However, receiver tilting causes the received optical power to deviate from the pre-established vertical fingerprint database, resulting in mismatches and decreased positioning accuracy. To address this challenge, we introduce a variable gain factor to convert the vertical fingerprint database into an inclined power database, thereby adapting to received power variations caused by receiver tilting and enhancing positioning accuracy. Furthermore, we propose a Transformer-enhanced MobileNetV3 network (ViTs-MNV3) for visible light positioning. This network utilizes the Transformer's multi-head attention mechanism to identify relationships between different input sequence components and learn global features, demonstrating enhanced performance. To increase simulation authenticity, we employ a depth camera to gather real-world point cloud data of mine walls and incorporate point cloud technology to construct a simulated underground mine environment that accurately reflects real-world conditions.

Results and Discussions In real-world environments, the fingerprint database collected under vertical reception

conditions is used to train the proposed network. A comparative study is conducted between the proposed ViTs-MNV3 network and four other models: MobileNetV3, Transformer neural network, backpropagation (BP) neural network, and long short-term memory (LSTM) network. The results demonstrate that the proposed network outperforms the other four networks in terms of positioning accuracy in real-world scenarios, proving its feasibility and superior robustness (Table 2 and Fig. 6). In an ideal simulated environment, the proposed network achieves a root mean square error (RMSE) of only 2.36 cm and an average positioning error of 3.2 cm in 3D positioning (Fig. 7). However, in the simulation space incorporating point cloud data of walls, the influence of wall reflections became significant, increasing the RMSE to 5.42 cm at a reception height of 1.2 m (Fig. 9). When the receiver tilted, the received power no longer matched the vertical fingerprint database, leading to substantial positioning errors (Fig. 10). To validate the practical applicability of the proposed algorithm, real-world positioning experiments are conducted. Optical power data are collected at four different heights under vertical reception conditions, and after deep network training, the final 3D RMSE reaches 10.95 cm, with an average error of 8.36 cm. The results achieved centimeter-level positioning accuracy, with 90% of errors below 25 cm and a low proportion of large errors (Fig. 12). Finally, a variable gain factor is applied to correct the vertical fingerprint database in real-world environments, transforming it into an inclined fingerprint database to match the received power under tilted reception conditions (Fig. 13). The transformed power closely resembles the actual inclined power measurements, and the RMSE is reduced to 21.43 cm (Fig. 14). However, compared to Fig. 12, this approach results in higher positioning errors due to the additional errors introduced by wall reflections during power transformation.

Conclusions This research presents a three-dimensional visible light positioning system designed for complex underground mine environments through the integration of 3D point cloud technology. The investigation examines multiple influential factors, including wall reflections, receiver height variations, and receiver tilting, each affecting positioning accuracy distinctly. Receiver tilting emerges as the most critical factor, resulting in an average positioning error of 2.17 m within a $4.0\text{ m} \times 3.0\text{ m} \times 2.5\text{ m}$ simulated environment, significantly impacting personnel positioning capabilities in underground mines. To mitigate this challenge, the study implements a variable gain factor to modify the vertical fingerprint database, converting it into an inclined fingerprint database that corresponds to received power under tilted reception conditions. This methodology substantially enhances positioning accuracy and facilitates the expansion of fingerprint databases for various tilt angles without requiring extensive manual data collection, thus optimizing resource efficiency. The positioning algorithm incorporates the strengths of the Transformer neural network and MobileNetV3 network, forming an innovative hybrid model, ViTs-MNV3, which exhibits exceptional performance in positioning applications. The algorithm achieves a RMSE of 2.36 cm in ideal simulated conditions and 5.42 cm in simulated environments with wall reflections. Experimental validation in real-world conditions demonstrates a RMSE of 10.95 cm under vertical reception conditions. Following power correction for tilted reception, although the RMSE increased to 21.43 cm, the corrected power values demonstrate substantial improvement in positioning accuracy compared to uncorrected tilted reception scenarios.

Key words visible light positioning; MobileNetV3; multi-head attention; point cloud technology; fingerprint database correction