

Beam-Steered Single-LED Single-PD Visible-Light Positioning for 3D Localization

Author Name, *Member, IEEE*, and Second Author, *Senior Member, IEEE*

Abstract—

Index Terms—VLP, Single LED VLP, CRLB, 3D positioning, GLS

I. INTRODUCCION

- K es el número total de orientaciones
- N es el número total de muestras por cada orientación
- C es la constante optica.

II. SYSTEM MODEL

En la Figura 1 se muestra el diagrama del sistema VLP a estudiar. El sistema está compuesto por un transmisor LED posicionado en el techo a una altura H , $\mathbf{T} = (0, 0, H)$, cuyo vector de orientación $\mathbf{n}_t$ es modulable; el receptor es un unico fotodiodo orientado verticalmente $\mathbf{n}_r = (0, 0, 1)$, de posición desconocida en el espacio tridimensional $\mathbf{R} = (x, y, z)$. Asimismo se denomina $\mathbf{d}$ como el vector distancia entre el transmisor y el receptor ($\mathbf{d} = \mathbf{R} - \mathbf{T}$).

Para la i -th orientación del transmisor de potencia P_t , la potencia recibida en el receptor es:

$$P_r^{(i)} = P_t h_{\text{LOS}}^{(i)} + \eta^{(i)}, \quad (1)$$

donde η es el zero-mean additive white Gaussian noise $\mathcal{N}(0, \sigma^2)$ y h_{LOS} es la ganancia del canal óptico definido por el modelo lambertiano:

$$h_{\text{LOS}} = \begin{cases} \frac{(m+1)A_{\text{det}}}{2\pi d^2} \cos \phi_i^m \cos \psi, & \psi \leq \Psi_{\text{FOV}}, \\ 0, & \text{otherwise,} \end{cases} \quad (2)$$

donde $m = \frac{-\ln 2}{\ln(\cos \Phi_{1/2})}$ es el orden lambertiano asociado al LED half-power angle $\Phi_{1/2}$, A_{det} es el área efectiva del fotodiodo, ϕ y ψ son los angulo de irradiancia e incidencia respectivamente, Ψ_{FOV} is the receiver field of view, d la distancia transmisor receptor. Además, el coseno de los angulos de irradiancia y de incidencia se pueden calcular como:

$$\cos \phi_i = \frac{\mathbf{n}_t^{(i)} \cdot \mathbf{d}}{d}, \quad \cos \psi = \frac{\mathbf{n}_r \cdot (-\mathbf{d})}{d}. \quad (3)$$

Por cada orientación se registran N -muestras en el receptor. El estimador eficaz de la potencia recibida en cada i -th orientación considerando el comportamiento de ruido gaussiano es la estadística siguiente:

$$P_r^{(i)} = \frac{1}{N} \sum_{j=1}^N P_{r,j}^{(i)}, \quad P_r^{(i)} \sim \mathcal{N}(\mu, \frac{\sigma^2}{N}) \quad (4)$$

The authors are with the Laboratoire d'Ingénierie des Systèmes de Versailles (LISV), Université of Paris-Saclay, UVSQ, 78140 Vélizy-Villacoublay, France (e-mail: aaaaa@uvsq.fr; aaaaa@uvsq.fr; aaaaa@uvsq.fr; aaaaa@uvsq.fr).




Fig. 1. Configuration of the system Single LED Visible Light Positioning.

la que consideraremos como potencia recibida promedio.

A. Método general de estimacion de posicion 3D Single LED

1) *Vector de direction finding*: En este primer paso se estima la dirección del transmisor para apuntar hacia el Receptor. Este es un vector unitario que se relaciona con el vector distancia $\mathbf{n}_d = \frac{\mathbf{d}}{\|\mathbf{d}\|}$. Para determinar la dirección se modula la orientación del transmisor K-veces. En las secciones V y VI se exploran diferentes métodos model-based para su estimación.

2) *Distance recovery*: Empleando la estimación de la dirección, reorientamos al Transmisor con $\mathbf{n}_t = \hat{\mathbf{n}}_d$, manteniéndose en un escenario beamsteering, sin perder generalización, asumimos que podemos reorientar el receptor y lo reorientamos para que apunte al transmisor con $\mathbf{n}_r = -\hat{\mathbf{n}}_d$ con la finalidad de maximizar la potencia recibida promedio. Se registran N muestras y se determina la distancia.

Considerando este alimentamiento, asumiendo que la constante

$$C = \frac{P_t(m+1)A_{\text{det}}}{2\pi}, \quad (5)$$

es conocida o calculada mediante calibración previa y empleando las ecuaciones eq.(1)(2)(3) se puede determinar que

$$\mu^* = \frac{C}{d^2} \quad (6)$$

donde μ^* es una muestra de la potencia recibida en este escenario. En la práctica, N independent samples $\{\mu_j^*\}_{j=1}^N$ are collected under this beamsteered configuration. Siguiendo

la eq.(4) se determina $\hat{\mu}^* = \frac{1}{N} \sum_{j=1}^N \mu_j^* \sim \mathcal{N}(\mu^*, \sigma^2/N)$. Substituting $\hat{\mu}^*$ into (6) y despejando la distancia tenemos:

$$\hat{d} = \sqrt{\frac{C}{\hat{\mu}^*}}. \quad (7)$$

La posición 3D estimada es:

$$\hat{\mathbf{R}} = \mathbf{T} + \hat{d} \hat{\mathbf{n}}_d. \quad (8)$$

III. POSITION ERROR BOUND

En esta sección se desarrolla la Position Error Bound (PEB), la cota inferior de Cramér–Rao (CRLB) aplicada al vector de posición, la cual determina la varianza mínima alcanzable por un estimador insesgado de la posición $\mathbf{R} = (x, y, z)^\top$ en el sistema propuesto. En este trabajo el PEB es empleado como métrica de referencia para cuantificar qué tan cercano al óptimo se sitúa un estimador específico y métrica para la optimización de parámetros del diseño que minimicen el error de posicionamiento.

A. Modelo estadístico conjunto de las observaciones

De acuerdo con la Sección II, para cada una de las K orientaciones del transmisor se calcula la potencia promedio

$$P_r^{(i)} \sim \mathcal{N}(\mu_i(\mathbf{R}), \sigma^2/N), \quad i=1, \dots, K,$$

donde $\mu_i(\mathbf{R}) = P_t h_{\text{LOS}}^{(i)}(\mathbf{R})$ y $h_{\text{LOS}}^{(i)}(\mathbf{R})$ se define en (2) con los cosenos dados en (3). Adicionalmente, tras la etapa de *beam-steering* se obtiene la estadística de *distance-recovery*

$$\mu^* \sim \mathcal{N}(C/d^2(\mathbf{R}), \sigma^2/N),$$

en la que $d(\mathbf{R}) = \|\mathbf{R} - \mathbf{T}\|$ y la constante C se definió en (5).

Agrupando todas las $(K+1)$ variables aleatorias se define el vector de mediciones

$$\mathbf{z} = [P_r^{(1)} \dots P_r^{(K)} \mu^*]^\top \sim \mathcal{N}(\boldsymbol{\mu}(\mathbf{R}), \boldsymbol{\Sigma}),$$

donde $\boldsymbol{\mu}(\mathbf{R}) = [\mu_1(\mathbf{R}), \dots, \mu_K(\mathbf{R}), \mu_{K+1}(\mathbf{R})]^\top$ y la matriz de covarianza es diagonal, $\boldsymbol{\Sigma} = \frac{\sigma^2}{N} \mathbf{I}_{K+1}$, gracias a la independencia de las mediciones y a la media muestral empleada en (4).

B. Función de log-verosimilitud y score

Considerando independencia entre las mediciones, la función de verosimilitud es el producto de $(K+1)$ densidades gaussianas idénticamente distribuidas. El principio de máxima verosimilitud para determinar la estimador eficaz se mantiene si se realiza a partir del logaritmo-verosimilitud, más conveniente para el cálculo, el cual se calcula como:

$$\ell(\mathbf{R}) = \ln L(\mathbf{R} | \mathbf{z}) = -\frac{N}{2\sigma^2} \sum_{i=1}^{K+1} [z_i - \mu_i(\mathbf{R})]^2 + \text{cte.} \quad (9)$$

El vector *score* se define como el gradiente de (9) respecto de los parámetros de interés:

$$\mathbf{s}(\mathbf{R}) = \nabla_{\mathbf{R}} \ell(\mathbf{R}) = \frac{N}{\sigma^2} \sum_{i=1}^{K+1} [z_i - \mu_i(\mathbf{R})] \nabla_{\mathbf{R}} \mu_i(\mathbf{R}),$$

donde $\nabla_{\mathbf{R}} = [\partial/\partial x, \partial/\partial y, \partial/\partial z]^\top$.

C. Matriz de Información de Fisher

Para distribuciones pertenecientes a la familia exponencial, tal como la gaussiana homocedástica de este trabajo, la Fisher Information Matrix (FIM) puede calcularse como la varianza del score, lo cual evita la diferenciación de segundo orden y resulta numéricamente más estable:

$$\mathbf{I}(\mathbf{R}) = \text{Var}[\mathbf{s}(\mathbf{R})] = \mathbb{E}_{\mathbf{z}}[\mathbf{s}(\mathbf{R}) \mathbf{s}^\top(\mathbf{R})] \quad (10)$$

$$= \frac{N}{\sigma^2} \sum_{i=1}^{K+1} [\nabla_{\mathbf{R}} \mu_i(\mathbf{R})] [\nabla_{\mathbf{R}} \mu_i(\mathbf{R})]^\top. \quad (11)$$

La última igualdad se obtiene usando que $\mathbb{E}[z_i] = \mu_i(\mathbf{R})$, de modo que $\mathbb{E}[(z_i - \mu_i)(z_j - \mu_j)] = 0$ cuando $i \neq j$. La información total es, por tanto, la superposición coherente de las contribuciones diferenciales de cada orientación y de la medida de distancia.

Gradientes necesarios:

1) Para la i -ésima orientación,

$$\nabla_{\mathbf{R}} \mu_i(\mathbf{R}) = P_t \nabla_{\mathbf{R}} h_{\text{LOS}}^{(i)}(\mathbf{R}),$$

siendo necesario derivar (2) empleando la regla de la cadena sobre $d(\mathbf{R})$, $\cos \phi_i$ y $\cos \psi$, resultando en:

$$\nabla_{\mathbf{R}} \mu_i(\mathbf{R}) = \frac{C}{d^3} \left[m \cos^{m-1} \phi_i \cos \psi \mathbf{n}_t^{(i)} - \cos^m \phi_i \mathbf{n}_r - (m+3) \cos^m \phi_i \cos \psi \mathbf{n}_d \right], \quad (12)$$

para $\psi > \Psi_{\text{FOV}}$ se anula el gradiente porque $h_{\text{LOS}}^{(i)} = 0$.

2) Para la ecuación de *distance-recovery*,

$$\nabla_{\mathbf{R}} \mu_{K+1}(\mathbf{R}) = -\frac{2C}{d^4} (\mathbf{R} - \mathbf{T}) = -\frac{2C}{d^3} \mathbf{n}_d, \quad (13)$$

donde $\mathbf{n}_d$ es el vector unitario definido en la Sección II-A.

D. Definición formal del PEB

Sea $\hat{\mathbf{R}}$ cualquier estimador insesgado de $\mathbf{R}$. El teorema de Cramér–Rao establece

$$\text{Cov}[\hat{\mathbf{R}}] \succeq \mathbf{I}^{-1}(\mathbf{R}),$$

por lo que una medida escalar de desempeño PEB se define como

$$\text{PEB}(\mathbf{R}) = \sqrt{\text{tr}\{\mathbf{I}^{-1}(\mathbf{R})\}}. \quad (14)$$

La raíz de la traza de la inversa de la FIM representa la *desviación estándar cuadrática mínima* (RMSE) que cualquier sistema VLP con las $K+1$ mediciones descritas podría alcanzar en la estimación de posición. Una PEB pequeña implica que el conjunto de orientaciones elegido y la medición

de rango aportan información suficiente y complementaria para localizar el receptor con alta precisión; en cambio, una PEB grande sugiere la necesidad de aumentar K , mejorar la relación señal-a-ruido, o rediseñar el patrón de orientaciones.

IV. OPTIMIZATION OF SET OF ORIENTATIONS

Como se puede apreciar en la eq. 12 el set de K orientaciones $\mathbf{n}_t^{(i)}$ impacta en la FIM, que a su vez impacta en la PEB. Por lo que es importante encontrar un set óptimo de orientaciones que minimice el PEB. Debido a la naturaleza no lineal de la función PEB, encontrar $\mathbf{n}_t^{(i)}$ tal que $\mathbf{n}_t^{(i)} = \text{argmin}(PEB)$ no es trivial. En el presente trabajo se propone el uso de algoritmos genéticos para la búsqueda del set de orientaciones óptimo para diferentes K que minimice el PEB global.

Los algoritmos genéticos se inspiran en la selección natural de darwin. Una población es generada aleatoriamente, se evalúa basado en una determinada métrica, los mejores sujetos denominados progenitores son seleccionados y cruzados, mientras que se añade a la población una tasa de individuos con mutación a fin de agregar variabilidad para no caer en mínimos locales; el proceso se repite por un número determinado de generaciones máxima. En el contexto de nuestro problema, los individuos tienen como características un set de K -orientaciones unitarias, cada vector de orientación es definido por completo con su ángulo de inclinación y azimuth (θ_i, ρ_i) el cual es equivalente a su vector unitario $\mathbf{n}_t^{(i)} = (\sin(\theta_i) \cos(\rho_i), \sin(\theta_i) \sin(\rho_i), -\cos(\theta_i))$. Es decir, para un set de K orientaciones, un individuo posee $2K$ características: $(\theta_1, \rho_1, \theta_2, \rho_2, \dots, \theta_K, \rho_K)$. La métrica de evaluación es el 90-percentil del PEB (es decir $PEB_{90\%}$) obtenido al evaluar en cada posición del recensor la eq.14 dentro de un grillado tridimensional que compone el testbed 3D. El algoritmo genético fue implementado en MATLAB y los parámetros empleados para la optimización se muestran en la tabla I.

TABLE I: Parámetros empleados en la optimización por algoritmo genético

Parámetros del sistema	
Parámetro	Valor
Posición del transmisor	$T = (0, 0, 2)$ m
Potencia óptica transmitida	$P_t = 0.405$ W
Ángulo semipotencia (half-power)	$\Phi_{1/2} = 45^\circ$
Orden Lambertiano	$m = -\ln 2 / \ln(\cos 45^\circ) = 2$
Área efectiva del fotodiodo	$A_{\text{det}} = 4.8 \times 5.5 \text{ mm}^2$
FOV del receptor	$\Psi_{\text{FOV}} = 85^\circ$
Varianza de ruido por muestra	$\sigma^2 = 10^{-21} \times 30 \times 10^6 \text{ W}^2$
Muestras por orientación	$N = 1000$
Algoritmo genético	
Parámetro	Valor
Población inicial	200
Generaciones máximas	200
Fracción de crossover	0.8
Función de mutación	@mutationadaptfeasible
Métrica de optimización	$PEB_{90\%}$
Parámetros a optimizar	$[\theta_1, \rho_1, \dots, \theta_K, \rho_K]$
Test-bed 3D	
Parámetro	Valor
Rango en x, y	$[-1.5, 1.5]$ m
Rango en z	$[0, 1.2]$ m
Paso de malla	0.2 m




Fig. 2. Desempeño del algoritmo con diferente número de orientaciones en 3 escenarios de $\Phi_{1/2}$.




Fig. 3. Desempeño del PEB ante diferentes medidas de ruido.

En la tabla II se muestra el resultado del proceso de optimización para cada uno de los escenarios de K evaluados y se expresa explícitamente las orientaciones. Notar que cada configuración de K tiene un distinto set de orientaciones óptimo. En la figura 2 se muestra el $PEB_{90\%}$ y como este se reduce conforme se incrementa el número de orientaciones. Se evaluó en 3 diferentes escenarios de potencia de ángulo medio. En todos los casos se puede notar que conforme el número de orientaciones aumenta se reduce el PEB, además en particular entre 5 a 6 orientaciones son necesarias para tener la reducción considerable del PEB mientras que más orientaciones aumentarán la latencia sin disminuir considerablemente el PEB. Asimismo, si bien el ángulo de potencia media de 30° obtiene menos errores ya que es más directivo, se trabajará con 45° ya presenta mayor regularidad en su curva y es seleccionada y comercialmente más común.

La figura 3 muestra el comportamiento del $PEB_{90\%}$ antes

TABLE II: Orientaciones óptimas (θ_i, ρ_i) en grados para distintos valores de K .

K	$i = 1$	$i = 2$	$i = 3$	$i = 4$	$i = 5$	$i = 6$	$i = 7$	$i = 8$	$i = 9$
3	(36.9,56.2)	(35.4,176.9)	(33.4,296.5)						
4	(36.9,17.6)	(41.6,198.6)	(42.4,108.4)	(39.4,293.6)					
5	(57.6,87.8)	(57.7,358.6)	(57.2,177.7)	(0.5,294.8)	(55.7,268.1)				
6	(53.2,179.8)	(59.0,355.4)	(48.4,97.8)	(49.6,268.1)	(19.8,252.8)	(26.0,39.2)			
7	(27.6,355.2)	(49.8,182.1)	(51.7,280.4)	(39.1,251.0)	(58.9,352.9)	(16.7,71.8)	(42.7,104.4)		
8	(32.8,218.2)	(28.5,61.5)	(51.9,178.2)	(35.7,25.5)	(51.6,338.8)	(57.7,273.6)	(49.7,106.2)	(18.1,243.2)	
9	(64.1,261.3)	(60.7,358.4)	(57.2,187.2)	(26.1,251.9)	(63.1,175.7)	(11.8,76.8)	(44.5,119.8)	(58.2,85.1)	(25.2,304.8)

el aumento de la varianza del ruido en distintos número de orientaciones. Como se puede apreciar el error incrementa con la varianza del ruido mientras que con respecto al número de orientaciones nuevamente entre 5 y 6 son las mínimas para un menor PEB en diferentes valores de ruido sin aumento de latencia.

V. ESTIMADOR NO LINEAL

Asimismo, se sabe que la potencia óptica colectada por el receptor depende directamente de la posición relativa de éste con respecto a la fuente óptica, en particular a través de los parámetros de distancia d , de ángulo de irradiancia $\phi_{t,i}$ y de ángulo de incidencia ψ_r .

Denotando $\mathbf{n}_r = [\alpha, \beta, \gamma]$, se observa que:

$$\cos \psi_r = \mathbf{n}_r \cdot -\mathbf{n}_d = -\frac{\alpha x + \beta y + \gamma(z - H)}{d}. \quad (15)$$

Donde x, y, z son las coordenadas del receptor, H es la altura del transmisor. Por tanto, usando 3, 15 y la relación $d = \sqrt{x^2 + y^2 + (z - H)^2}$ en 1 y luego sustituyendo el resultado en 4, se deduce que:

$$P_{o,r}^{(i)} = -C \frac{(a_i x + b_i y + c_i(z - H))^m}{[x^2 + y^2 + (z - H)^2]^{\frac{m+3}{2}}} (\alpha x + \beta y + \gamma(z - H)) + n. \quad (16)$$

Se observa, por tanto, que las potencias observadas se relacionan directamente con los parámetros a estimar, es decir las coordenadas $\mathbf{R} = (x, y, z)$ del receptor, pero de forma no lineal. Para buscar el vector dirección $\mathbf{n}_d$ en lugar de las coordenadas $\mathbf{R}$, se debe imponer la restricción $x^2 + y^2 + (z - H)^2 = 1$. La ecuación 16 puede reformularse entonces como:

$$P_{o,r}^{(i)} = -C Q_i^m(x, y, z) L(x, y, z) + n, \quad (17)$$

con $n \sim \mathcal{N}(0, \sigma^2/N)$ y:

$$Q_i(x, y, z) = a_i x + b_i y + c_i(z - H), \quad (18)$$

$$L(x, y, z) = \alpha x + \beta y + \gamma(z - H). \quad (19)$$

Nos encontramos aquí ante un caso típico de la teoría de la estimación, donde las observaciones promedio $(P_{o,r}^{(i)})$ para diferentes orientaciones i están unidas no linealmente a los parámetros a estimar y contaminadas por ruido gaussiano de densidad conocida. Se sabe que en este contexto no existe un estimador eficiente, pero sí puede hallarse un estimador MVU.

Para ello se resuelve el problema de mínimos cuadrados no lineales minimizando la función de coste $F(x, y, z)$ definida como:

$$F(x, y, z) = \sum_{i=1}^K F_i(x, y, z), \quad (20)$$

con:

$$F_i(x, y, z) = (P_{o,r}^{(i)} - (-C) Q_i(x, y, z) L(x, y, z))^2. \quad (21)$$

Cabe señalar que, puesto que buscamos la estimación de la dirección $\mathbf{n}_d$, las coordenadas $x, y, (z - H)$ resultantes de este problema de mínimos cuadrados han de pertenecer a la esfera unitaria $\mathbb{S}^2$ y garantizar que los polinomios $Q_i(x, y, z)$ y $L(x, y, z)$ sean, respectivamente, positivos (pues iguales a $\cos \phi_i$, con $0 \leq \phi_{t,i} \leq \pi/2$) y negativos (pues iguales a $-\cos \psi_r$, con $0 \leq \psi_r \leq \pi/2$).

En otras palabras, buscamos una estimación $\hat{\mathbf{n}}_d$ del vector unitario $\mathbf{n}_d$, apuntando de la fuente óptica al receptor, que sea solución del problema de mínimos cuadrados no lineales:

$$\hat{\mathbf{n}}_{d, \text{NL}} = \arg \min_{(x, y, z-H) \in \mathbb{S}^2} F(x, y, z). \quad (22)$$

con $F(x, y, z)$ definido en 20-21 y Q_i, L según 18-19, sujeto a las restricciones:

$$\begin{aligned} x^2 + y^2 + (z - H)^2 &= 1, \\ \forall i \in \{1, \dots, K\}, \quad Q_i(x, y, z) &\geq 0, \\ L(x, y, z) &\leq 0. \end{aligned} \quad (23)$$

En la práctica, este problema puede resolverse en MATLAB mediante la función `solve`, que para este tipo de optimización no lineal recurre internamente a `fmincon` e implementa métodos de descenso de gradiente.

VI. LINEAL ESTIMATOR

The present section develops the first stage with full mathematical rigour and presents two statistically grounded estimators: (i) generalised least squares (GLS), which is minimum-variance under Gaussian noise with known covariance, and (ii) weighted least squares (WLS), an inexpensive approximation that neglects the weak cross-correlation between equations.




Fig. 4. Distribución de la potencia optica en el receptor para una configuración de $K = 5$ orientaciones.

A. Direction Estimation via GLS

This subsection consolidates the analytical pipeline that converts the raw optical powers into a closed-form, statistically efficient estimate of the direction vector $\mathbf{n}_d$. The exposition proceeds from the deterministic constraints, through a rigorous stochastic characterisation of the residuals, to the final GLS solution.

1) *Lambertian power ratios and homogeneous constraints:* Let $\mu_i = \mathbb{E}[P_r^{(i)}]$ be the noise-free power at orientation i . We define power ratio β as:

$$\beta_i = (\mu_i/\mu_1)^{1/m}, \quad i = 2, \dots, K, \quad (24)$$

and, from eq.(1), (2) and (3), $\mu_i \propto (\mathbf{d} \cdot \mathbf{n}_t^{(i)})^m$, each β_i imposes

$$\mathbf{d} \cdot (\mathbf{n}_t^{(i)} - \beta_i \mathbf{n}_t^{(1)}) = 0, \quad i = 2, \dots, K. \quad (25)$$

Denoting $\mathbf{a}_i = \mathbf{n}_t^{(i)} - \beta_i \mathbf{n}_t^{(1)}$, (25) reads $\mathbf{a}_i \cdot \mathbf{d} = 0$ and supplies $K - 1$ homogeneous hyperplanes that intersect at the true $\mathbf{d}$.

2) *Stochastic perturbation of the ratios:* Let $P_{r,k}^{(i)}$ denote the k -th noisy observation gathered while the LED points along $\mathbf{n}_t^{(i)}$, $1 \leq k \leq N$, $1 \leq i \leq K$. According to (1), $P_{r,k}^{(i)} = \mu_i + \eta_i$ with $\eta_i \sim \mathcal{N}(0, \sigma^2)$ i.i.d. The sample mean

$$\hat{\mu}_i = \frac{1}{N} \sum_k P_{r,k}^{(i)} \sim \mathcal{N}(\mu_i, \sigma^2/N)$$

is the MVU estimator. Injecting $\hat{\mu}_i$ into (24) yields

$$\hat{\beta}_i = g_i(\hat{\mu}_1, \hat{\mu}_i), \quad g_i(x_1, x_2) = \left(\frac{x_2}{x_1}\right)^{\frac{1}{m}}.$$

A first-order Taylor expansion of g_i centred at $\boldsymbol{\mu}_i = (\mu_1, \mu_i)^\top$ gives

$$\hat{\beta}_i \approx \bar{\beta}_i + \frac{\bar{\beta}_i}{m} \left(\frac{\eta_i}{\mu_i} - \frac{\eta_1}{\mu_1} \right), \quad \bar{\beta}_i = (\mu_i/\mu_1)^{1/m}. \quad (26)$$

Hence every $\hat{\beta}_i$ shares the common perturbation η_1 , producing correlation across orientations.

Define the ratio error $\tilde{\eta}_i = \hat{\beta}_i - \bar{\beta}_i$. Using (26) and the independence of η_i and η_1 ,

$$\text{Var}[\tilde{\eta}_i] = \frac{\sigma^2}{Nm^2} \bar{\beta}_i^2 (\mu_i^{-2} + \mu_1^{-2}), \quad (27)$$

$$\text{Cov}[\tilde{\eta}_i, \tilde{\eta}_j] = \frac{\sigma^2}{Nm^2} \bar{\beta}_i \bar{\beta}_j \mu_1^{-2}, \quad i \neq j. \quad (28)$$

The factor $(\mu_i^{-2} + \mu_1^{-2})$ in (27) demonstrates that the variance of $\tilde{\eta}_i$ depends explicitly on μ_i , even though each $\eta_k^{(i)}$ has the same variance σ^2 . In other words, a single-LED system exhibits *heteroscedastic* ratio errors.

3) *Residuals and their covariance.:* Substituting $\hat{\beta}_i$ into $\mathbf{a}_i$, $\mathbf{a}_i = \bar{\mathbf{a}}_i - \mathbf{n}_t^{(1)} \tilde{\eta}_i$, and taking the inner product with $\mathbf{d}$ gives the residual

$$r_i = \mathbf{a}_i \cdot \mathbf{d} = \kappa \tilde{\eta}_i, \quad \kappa = \mathbf{n}_t^{(1)} \cdot \mathbf{d}.$$

Consequently, vector of residuals $\mathbf{r} = [r_2, \dots, r_n]^\top$ is zero-mean Gaussian with covariance $\Sigma_r = \kappa^2 \Sigma_\beta$,

$$\mathbf{r} = \mathbf{A}^\top \mathbf{d} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \Sigma_r),$$

where Σ_β gathers (27)–(28). Higher-order remainders decay as $O(\sigma^4/N^2)$ and are negligible for $\text{SNR} \geq 10$ dB and $N \geq 50$.

4) *GLS formulation and closed-form solution*: Collect the normals as $A = [\mathbf{a}_2 \dots \mathbf{a}_n] \in \mathbb{R}^{3 \times (n-1)}$. With Σ_r known, the generalised least-squares problem is

$$\hat{\mathbf{d}} = \arg \min_{\|\mathbf{d}\|=1} \mathbf{d}^\top (A \Sigma_r^{-1} A^\top) \mathbf{d},$$

whose minimiser is the unit eigenvector associated with the smallest eigenvalue of $M_{\text{GLS}} = A \Sigma_r^{-1} A^\top$. In practice, all multiplicative constants in Σ_r^{-1} can be omitted and absorbed into a normalisation of the weight matrix, since only the eigenvector direction matters. Formally,

$$\hat{\mathbf{n}}_{d,\text{GLS}} = \frac{\mathbf{v}_{\min}(M_{\text{GLS}})}{\|\mathbf{v}_{\min}(M_{\text{GLS}})\|} \quad (29)$$

and the sign of $\hat{\mathbf{n}}_{d,\text{GLS}}$ is chosen so that $\hat{\mathbf{n}}_{d,\text{GLS}} \cdot \mathbf{n}_t^{(1)} > 0$, ensuring the vector points from the transmitter towards the receiver. This estimator is the minimum-variance, unbiased linear estimator (BLUE) for the linearised model.

B. WLS as a practical simplification

The inversion of Σ_r requires an $(n-1) \times (n-1)$ Cholesky factorisation. For real-time, low-power receivers a lighter alternative is attractive. Neglecting the off-diagonal terms in (28) gives the diagonal weight matrix

$$\tilde{\Sigma}_r = \text{diag}\left\{\bar{\beta}_i^2(\mu_i^{-2} + \mu_1^{-2})\right\}_{i=2}^n.$$

Setting $W = \tilde{\Sigma}_r^{-1}$ leads to the WLS cost

$$J_{\text{WLS}}(\mathbf{d}) = \mathbf{d}^\top (A W A^\top) \mathbf{d}, \quad \|\mathbf{d}\| = 1,$$

whose minimiser is

$$\hat{\mathbf{n}}_{d,\text{WLS}} = \frac{\mathbf{v}_{\min}(A W A^\top)}{\|\mathbf{v}_{\min}(A W A^\top)\|}. \quad (30)$$

The neglected off-diagonal covariance terms scale as μ_1^{-2} , whereas the diagonal entries scale as $\mu_i^{-2} + \mu_1^{-2}$. When the reference orientation ($i = 1$) satisfies $\mu_1 \gg \mu_i$ for most i , one obtains $\mu_1^{-2} \ll \mu_i^{-2}$, so that the off-diagonal terms are at least 20 dB below the diagonal terms. In such regimes, the WLS estimator captures over 95% of the statistical efficiency of GLS while avoiding matrix inversions. In contrast, in nearly symmetric geometries where $\mu_i \approx \mu_1$ for many i , off-diagonal correlations become important and the full GLS should be used for optimal performance.

C. Number of orientations

The algebraic and statistical behaviour of the GLS/WLS estimator hinges on the rank of A , which in turn depends on the cardinality and geometry of the steering set $\{\mathbf{n}_t^{(i)}\}_{i=1}^n$:

a) $n = 3$ (*just-determined*): when the three orientations are not coplanar, A attains rank 2 and the information matrix M_{GLS} has one null eigenvalue. The remaining two eigenvalues yield a *unique* solution, which reduces to the closed-form cross product $\hat{\mathbf{d}} \propto \mathbf{a}_2 \times \mathbf{a}_3$ for both GLS and WLS. However, any near-coplanarity inflates the smallest non-zero eigenvalue and amplifies noise.

Algorithm 1 3-D Position Estimation from n Orientations

Require: Power samples $P_{r,k}^{(i)}$ ($k = 1, \dots, N$, $i = 1, \dots, K$); steering vectors $\mathbf{n}_t^{(i)}$; Lambertian order m ; noise variance σ^2 ; MODE $\in \{\text{GLS}, \text{WLS}\}$; radiometric constant C .

Ensure: $\hat{\mathbf{R}}$ (3-D position of the receiver)

```

1: Direction finding:
2:   Compute  $\hat{\mu}_i = \frac{1}{N} \sum_{k=1}^N P_{r,k}^{(i)}$  for  $i = 1, \dots, K$ 
3:   Compute  $\hat{\beta}_i = (\hat{\mu}_i / \hat{\mu}_1)^{1/m}$  for  $i = 2, \dots, K$ 
4:   Form  $\mathbf{a}_i = \mathbf{n}_t^{(i)} - \hat{\beta}_i \mathbf{n}_t^{(1)}$ 
5:   Set  $A = [\mathbf{a}_2, \dots, \mathbf{a}_n]$ 
6:   if MODE = GLS then
7:     Build  $\Sigma_r$  via (27)–(28), substituting  $\beta_i \leftarrow \hat{\beta}_i$ 
8:      $M \leftarrow A \Sigma_r^{-1} A^\top$ 
9:   else ▷ WLS (diagonal approximation)
10:     $\tilde{\Sigma}_r \leftarrow \text{diag}\{\hat{\beta}_i^2(\hat{\mu}_i^{-2} + \hat{\mu}_1^{-2})\}$ 
11:     $M \leftarrow A \tilde{\Sigma}_r^{-1} A^\top$ 
12:   end if
13:   Compute  $\mathbf{v}_{\min}$  = eigenvector of  $M$  with smallest eigenvalue
14:    $\hat{\mathbf{n}}_d \leftarrow \mathbf{v}_{\min} / \|\mathbf{v}_{\min}\|$ 
15:   if  $\hat{\mathbf{n}}_d \cdot \mathbf{n}_t^{(1)} < 0$  then
16:      $\hat{\mathbf{n}}_d \leftarrow -\hat{\mathbf{n}}_d$  ▷ Ensure pointing to Rx
17:   end if

18: Distance Estimation (beamsteering):
19:   Set  $\mathbf{n}_t \leftarrow \hat{\mathbf{n}}_d$ ,  $\mathbf{n}_r \leftarrow -\hat{\mathbf{n}}_d$ 
20:   Collect  $N$  power samples  $P_r^{*(k)}$ 
21:   Compute  $\hat{\mu}^* = \frac{1}{N} \sum_{k=1}^N P_{r,k}^*$ 
22:    $\hat{d} \leftarrow \sqrt{\frac{C}{\hat{\mu}^*}}$ 

23: Final 3-D position:
24:    $\hat{\mathbf{R}} \leftarrow \mathbf{T} + \hat{d} \hat{\mathbf{n}}_d$ 
25: return  $\hat{\mathbf{R}}$ 

```

b) $n \geq 4$ (*over-determined*): additional, non-redundant orientations populate the third dimension of the normal space, elevate the rank of $A \Sigma_r^{-1} A^\top$ to 3, and turn the optimisation into a genuine Rayleigh quotient (GLS/WLS) whose minimum is strictly positive.




Fig. 5. Comparación de CDF de diferentes métodos y K .

VII. RESULTS AND SIMULATIONS

En la Figura 5 se muestra el CDF del error de estimación de la posición por cada uno de los métodos presentados previamente, empleando un set de K -orientaciones para $K = 5$ y 9. Como se puede apreciar el método GLS presenta un desempeño comparable con el método NL y cercanos al PEB; mientras que el WLS presenta un mayor error pero es de menor complejidad, lo que impacta en la latencia.

La Figura 6 muestra una comparativa entre el CDF del error al 90% ($e_{90\%}$) de los diferentes métodos y la latencia, para los escenarios de $K = 5$ y 9. Como se puede apreciar el método NL presenta una mayor latencia debido a que es un método que recurre iterativamente a la búsqueda de la solución; mientras que los otros métodos GLS y WLS son soluciones cerradas.




Fig. 6. Latencia de los diferentes métodos.

La Figura 7 muestra la estimación de la posición del receptor por el método WLS y GLS con $K = 5$ en 3 diferentes alturas $h(0, 0.6, 1.2)$ y la referencia de la posición real. Como se puede apreciar cuando $h = 1.2$ el error aumenta conforme estamos en los extremos especialmente en las esquinas debido a que se tiene menor SNR por los ángulos extremos que forma con los vectores de orientación; mientras que en $h = 0$ la estimación es más uniforme.




Fig. 7. Estimación de la posición en 3D para 3 diferentes niveles de altura considerando $K = 5$ orientaciones. GLS de azul, WLS de rojo, Referencias de negro.